

AI技术应用验证报告

学号：2023141461061

姓名：袁新坪

项目名称：AI辅助软件过程改进平台

文档版本：V1.0

编写日期：2026年7月

摘要

为验证人工智能技术在软件过程改进中的实际价值，本文选择需求质量检查、测试用例生成、代码评审辅助和项目知识问答四个场景开展课程实验。验证重点不是比较模型的通用能力，而是观察AI嵌入软件流程后，能否减少重复劳动、提前发现问题、提高文档完整性和增强项目知识复用。

本报告给出了验证目标、实验环境、样本设计、评价指标、执行过程、结果分析和风险结论。实验采用课程项目数据和构造样本，所有AI输出均由人工复核。验证结果表明，AI在需求歧义发现、测试场景扩展和文档检索方面具有较高价值；在复杂业务逻辑判断和代码安全结论方面仍存在误报与遗漏，必须与规则工具和人工评审结合。

关键词： AI验证；需求分析；测试生成；代码评审；知识问答；软件过程改进

1. 验证目的

本次验证回答以下问题：

- AI能否发现需求中的模糊、遗漏和不可测试内容；
- AI生成的测试用例能否补充边界和异常场景；
- AI代码评审能否发现常规缺陷并提供可执行建议；
- 基于项目资料的知识问答能否提高信息检索效率；
- AI输出的准确性、采用率和风险是否可接受；
- AI能力是否适合进入正式软件过程。

2. 验证范围

2.1 验证场景

编号	场景	验证内容
V01	需求质量检查	歧义、遗漏、验收标准和风险提示
V02	测试用例生成	正常、边界、异常、权限和并发场景
V03	代码评审辅助	正确性、异常处理、性能和可维护性
V04	项目知识问答	基于文档检索并回答项目问题

2.2 不在验证范围内的内容

- 不验证AI自动批准代码合并；
- 不验证AI自动发布生产版本；
- 不让AI独立进行安全审计；
- 不使用真实个人隐私和生产敏感数据；
- 不将AI建议直接视为最终结论。

3. 实验环境

3.1 数据集


本次课程验证使用以下样本：

数据类型	数量	说明
需求条目	20条	包括完整需求和故意加入问题的需求
接口说明	8份	包含参数、返回值和异常码
代码变更片段	15组	涵盖空值、权限、查询和异常处理
历史缺陷记录	12条	用于知识检索和相似问题分析
项目规范文档	6份	包括编码、测试、提交和发布规范

数据类型	数量	说明
人工基准测试用例	60条	由人工编写，作为对照

说明：以上数据用于课程实验和方法验证，不代表生产系统统计结果。

3.2 验证流程



3.3 人工评审规则

每条AI输出按以下标准分类：

- **正确：** 问题判断正确，建议可采用；
- **部分正确：** 方向正确，但信息不完整或表达不准确；
- **错误：** 判断与事实不符；
- **无效：** 内容空泛，无法执行；
- **新增价值：** 人工基准未覆盖，但经确认确有价值。

4. 评价指标

4.1 准确率

准确率 = 正确建议数 / AI建议总数

4.2 召回率

召回率 = AI发现的基准问题数 / 人工基准问题总数

4.3 采用率

采用率 = 被直接或修改后采用的建议数 / AI建议总数

4.4 时间节省率

时间节省率 = (纯人工时间 - AI辅助时间) / 纯人工时间

4.5 新增场景率

新增场景率 = AI新增且有效的测试场景数 / AI生成场景总数

4.6 可追溯性

知识问答结果是否能够给出来源文档或相关片段，不仅给出结论。

5. 场景一：需求质量检查验证

5.1 实验方法

选取20条需求，其中：

- 8条相对完整；
- 6条包含模糊词；
- 3条缺少异常场景；
- 3条存在不可验证的性能或体验表述。

AI根据统一检查模板输出：

1. 问题位置；
2. 问题类型；
3. 影响；
4. 修改建议；
5. 推荐验收标准；
6. 风险等级。

5.2 示例

原始需求：

用户提交表单后，系统应尽快保存数据；如果输入有问题，应给出合理提示。

AI识别的问题：

- “尽快”不可度量；
- “输入有问题”未定义错误类型；
- “合理提示”缺少格式和内容要求；
- 未说明重复提交；
- 未说明网络失败和服务异常；
- 未说明保存成功后的页面状态。

修改后的验收标准示例：

- 正常网络条件下，提交响应时间不超过2秒；
- 必填字段缺失时，在对应字段下显示错误提示；
- 重复提交不得生成重复数据；
- 保存失败时保留用户输入并显示可理解的错误信息；
- 保存成功后显示成功提示并更新列表。

5.3 结果

指标	结果
人工基准问题数	42
AI发现基准问题数	36
AI建议总数	51
正确建议数	39
部分正确建议数	8
错误或无效建议数	4
新增且有效问题数	6
准确率	76.5%
基准问题召回率	85.7%
建议采用率	80.4%

5.4 分析

AI对模糊词、缺失异常场景和验收标准生成表现较好。对于需要深度业务知识的规则，AI可能给出不适用的通用建议。因此需求检查适合作为评审前置环节，但必须由需求负责人确认。

6. 场景二：测试用例生成验证

6.1 实验方法

选取5个功能需求和3个接口说明，要求AI按照统一模板生成测试用例，并与人工基准用例比较。

要求覆盖：

- 正常流程；
- 边界值；
- 异常输入；
- 权限控制；
- 重复操作；
- 并发和幂等；
- 数据一致性；
- 错误恢复。

6.2 示例：登录功能

AI生成的测试场景包括：

- 正确账号和密码；
- 错误密码；
- 不存在账号；
- 禁用账号；
- 空账号；
- 空密码；
- 超长输入；
- 特殊字符；
- 连续失败锁定；
- 锁定后再次登录；
- 会话过期；
- 多终端登录；

- 网络中断；
- 服务异常；
- SQL注入和脚本输入。

人工评审发现，AI对异常和安全场景覆盖较丰富，但部分场景的预期结果依赖系统实际策略，需要修改后使用。

6.3 结果

指标	结果
人工基准用例	60
AI生成用例	93
与人工基准重复或等价	52
AI新增有效用例	24
需修改后采用	11
无效或重复用例	6
基准覆盖率	86.7%
AI用例有效率	93.5%
新增有效场景率	25.8%

6.4 时间对比

活动	纯人工	AI辅助
阅读需求	30分钟	30分钟
设计测试场景	120分钟	35分钟
完善步骤与预期	90分钟	60分钟
评审与去重	30分钟	45分钟
总计	270分钟	170分钟

时间节省约为37%。AI显著缩短了初稿生成时间，但增加了筛选和去重工作。

6.5 分析

AI适合生成测试场景初稿，尤其能够提醒边界、异常和权限问题。但AI可能生成系统不支持的场景，也可能重复表达相同用例。因此应将输出导入测试管理流程后由测试人员确认。

7. 场景三：代码评审辅助验证

7.1 实验方法

准备15组代码变更片段，覆盖：

- 空值处理；
- 权限校验；
- 数据库查询；
- 异常吞噬；
- 资源释放；
- 重复代码；
- 输入校验；
- 并发更新；
- 日志记录；
- 敏感信息输出。

AI输出分为高、中、低三个风险等级。

7.2 示例问题

示例代码逻辑：

根据用户传入的ID查询记录；

如果查询结果为空，后续仍直接访问对象字段；

异常被捕获后只打印信息，不继续抛出或返回错误。

AI应识别：

- 可能发生空指针异常；
- 异常处理导致调用方误判成功；
- 日志缺少上下文；
- 建议增加明确返回值和统一异常处理。

7.3 结果

指标	结果
人工预置问题	34
AI发现问题	27
AI额外建议	19
正确额外建议	8
错误或低价值建议	11
基准问题召回率	79.4%
AI建议准确率	69.6%
高风险问题召回率	88.9%

7.4 发现的问题

AI代码评审存在以下局限：

- 1. 缺少完整项目上下文时容易误判；
- 2. 对框架默认行为理解不稳定；
- 3. 容易给出过度重构建议；
- 4. 对复杂权限和事务规则判断不足；
- 5. 建议有时正确但定位不精确；
- 6. 不能替代静态分析和安全扫描。

7.5 结论

AI代码评审适合用于评审前的辅助筛查，尤其适合解释可读性、异常处理和常规风险。正式流程应采用“静态分析 + AI建议 + 人工评审”三层机制。

8. 场景四：项目知识问答验证

8.1 实验方法

将6份项目规范文档和12条历史缺陷记录建立知识索引，设计30个问题：

- 10个可从单一文档直接回答；
- 10个需要跨文档整合；
- 5个信息不足，应明确回答无法确定；
- 5个包含容易诱导模型猜测的问题。

8.2 问题示例

- 合并请求必须满足哪些条件？
- 发布前是否要求数据库备份？
- 缺陷严重程度如何划分？
- 某个历史登录问题最终如何解决？
- 项目是否支持某个未在文档中说明的功能？

8.3 结果

指标	结果
问题总数	30
回答正确	23
部分正确	4
错误	1
应拒答且正确拒答	2
提供有效来源	27
综合准确率	76.7%
来源覆盖率	90.0%

8.4 分析

基于项目知识检索后，回答质量明显高于直接使用通用模型。主要问题是文档本身存在冲突或信息缺失时，系统可能选择错误片段。知识库上线前应进行文档版本管理和失效资料清理。

9. 综合结果

场景	准确性	效率改善	风险	是否建议进入试点
需求质量检查	较高	明显	低至中	是
测试用例生成	较高	明显	中	是
代码评审辅助	中等	一般	中至高	限定范围试点
项目知识问答	较高	明显	中	是

9.1 综合评分

采用5分制评价：

维度	需求检查	测试生成	代码评审	知识问答
业务价值	5	5	4	4
输出准确性	4	4	3	4
可实施性	5	4	3	5
风险可控性	4	4	3	4
数据准备度	4	4	3	5
总分	22	21	16	22

10. 失败案例与问题分析

10.1 需求场景中的过度补充

AI可能将行业通用规则当作项目真实要求。例如，在没有说明的情况下自动增加强制锁定、验证码或审批流程。此类建议需要标记为“候选要求”，不能直接写入正式需求。

10.2 测试场景中的重复

AI常使用不同表述生成实质相同的测试用例。需要增加语义去重和测试人员审核。

10.3 代码评审中的上下文不足

仅输入代码差异时，AI可能不了解已有校验、框架约束和调用链。应补充相关接口、数据模型和项目规范，并限制模型对未知信息进行推断。

10.4 知识问答中的旧文档干扰

当知识库同时存在旧版和新版规范时，检索结果可能冲突。必须保存版本、发布日期和有效状态，并优先检索当前有效文档。

11. 风险控制措施

1. 所有AI输出必须标注“建议”或“草稿”；
2. 关键内容必须人工确认；
3. 输入数据进行脱敏；
4. 模型不得直接获得生产密码和密钥；
5. 知识问答必须提供来源；
6. 保存调用记录和人员修改记录；
7. 设置低置信度拒答；
8. 对高风险代码问题使用确定性工具复核；
9. 定期统计误报率和采纳率；
10. 发现严重错误时可快速关闭对应AI功能。

12. 验证结论

本次验证表明，AI技术适合进入软件过程中的辅助环节，但不适合直接承担最终审批和高风险决策。

推荐优先落地：

- 需求质量检查；
- 测试场景生成；
- 项目知识问答。

代码评审建议先在低风险模块试点，并与静态分析和人工评审结合。后续应持续收集以下数据：

- 建议采纳率；

- 人工修改比例；
- 误报和漏报；
- 时间节省；
- 缺陷提前发现数量；
- 用户满意度；
- 模型调用成本。

只有当AI辅助确实改善工程结果，而不是单纯增加生成内容时，才应扩大使用范围。

附录A：验证记录模板

字段	内容
验证编号	V-YYYYMMDD-XXX
场景	需求/测试/代码/知识
输入样本	样本编号
模型输出	原始输出
人工结论	正确/部分正确/错误/无效
是否采用	是/修改后采用/否
修改内容	人工调整说明
风险说明	可能影响
评审人	姓名
日期	日期

附录B：AI输出评审清单

- ☐ 是否基于已知事实
- ☐ 是否包含无法确认的推断
- ☐ 是否遗漏关键场景
- ☐ 是否存在重复内容
- ☐ 是否符合项目规范

- ☐ 是否涉及敏感信息
- ☐ 是否给出可执行建议
- ☐ 是否需要其他工具验证
- ☐ 是否已由人员确认