

AI 技术调研与场景分析

1. 文档定位与研究对象

智能交通 OD 预测项目以“区域之间的出行需求”为建模对象，将城市划分为 16×16 网格，以 60 分钟为时间粒度，预测未来 12 个时间步的 OD 矩阵。项目并非单纯追求一个漂亮的模型分数，而是把数据治理、模型训练、过程评估和调度应用连接为一条可审计的软件过程链。

本文围绕 AI 技术调研与场景分析展开，采用 Markdown 式层级结构组织内容。报告不把“AI”当作装饰性标签，而将其放入可验证的交通业务场景：早晚高峰潮汐、极端天气扰动、跨城区通勤、低频边缘区域和大型活动冲击。技术是否先进并不天然等于项目成功，只有当模型输出能够被调度人员解释、被软件过程追踪、被验证指标约束时，AI 才真正进入软件工程语境。

调研边界设定为三类技术：时序预测模型、图神经网络模型和面向软件过程的生成式 AI 工具。前两类负责提升 OD 预测精度，后一类辅助需求分析、测试用例生成、实验复盘与文档维护。

从交付物角度看，本页承担文档入口功能，因此除界定研究对象外，还需要把“技术调研”和“软件过程”连接起来。若只说明模型名称，报告会停留在工具清单；若把模型输出、过程证据与业务场景同时呈现，读者才能判断该技术是否适合课程项目。后续章节均围绕这一逻辑展开：技术被放入场景，场景被转化为指标，指标再回到过程控制。

2. 业务痛点与 AI 介入必要性

传统交通预测常把区域流量视为单点时间序列，容易忽略“从哪里来、到哪里去”的空间依赖。以某城市 90 天网约车订单为例，约 87.6 万条记录被聚合为 $16 \times 16 \times 24$ 的 OD 张量；其中 79.4% 的 OD 单元在大多数时段为零，8.7% 的单元贡献了超过 63% 的高峰出行量。稀疏性与集中性同时存在，正是 OD 预测最难处理的结构矛盾。

如果只用历史均值，模型能在平稳时段维持可接受误差，却会在雨天晚高峰或大型活动散场时失效。业务端真正关心的并非平均误差，而是“关键区域是否提前 30-60 分钟被识别”“调度建议是否能减少空驶”“模型是否在异常事件中保持可解释边界”。AI 的价值由此从算法竞赛转向过程改进。

- 早高峰潮汐流要求模型捕获方向性变化，而不仅是总量变化。
- 极端天气场景需要融合外生变量，单纯依赖历史订单会产生滞后。
- 低频边缘区域样本少，模型过拟合与忽略需求的风险并存。
- 跨城区通勤存在长程依赖，普通 RNN 容易低估远距离 OD。

业务痛点并非抽象困难，而是可观测的工程压力。以 16×16 网格为例，单日会产生 1,572,864 个候选 OD 单元，绝大多数单元为零；然而调度价值恰恰集中在少量非零、高峰、跨区单元中。模型若把“多数为零”学得过好，平均误差会下降，真实需求却被漏掉。这种风险要求技术调研必须同时审查精度和召回。

3. 技术路线总览

图 1 智能交通 OD 预测技术链路



链路将软件工程过程中的需求、设计、验证与运行反馈映射到 AI 模型生命周期。

图 1 智能交通 OD 预测技术链路

图 1 将数据、模型和应用端连接为完整链路。数据层承担清洗、对齐和语义补强；建模层把时间依赖与空间图结构耦合；应用层把预测结果压缩为可操作信号，例如热区预警、候选调度区域、异常 OD 排名。这个链路看似线性，实际存在持续回流：验证阶段发现高峰欠拟合后，需求分析与特征工程必须重新审查，而不是单纯堆叠模型层数。

在软件过程视角下，AI 技术路线同时生成三类工作产品：数据版本、模型版本和评估证据。缺少任意一类，项目都会沦为一次性实验。

该链路也暴露出责任分界：数据负责人对清洗规则负责，算法负责人对训练配置负责，评估负责人对指标解释负责，项目负责人对最终场景适配负责。AI 系统的质量不应被理解为模型文件质量，而是由数据、代码、参数、文档与应用反馈共同构成。只有链路中的每个节点能留下工作产品，后续复盘才不会变成口头回忆。

4. 代表技术对比

技术类别	代表方法	适用任务	优势	局限
统计模型	Historical Average/ARIMA	平稳通勤规律	解释简单、成本低	难以捕获突发扰动
循环网络	GRU/LSTM	短期时间依赖	训练稳定、部署方便	空间关系表达不足
图神经网络	STGCN/Graph WaveNet	区域关联预测	能建模邻接与扩散	图结构依赖人为设定
注意力模型	Transformer/TFT	长程依赖与外生变量	适合多变量融合	数据量不足时易过拟合
生成式 AI	LLM 辅助过程管理	需求/测试/文档	提升过程效率	需人工审查与保密控制

表 1 代表 AI 技术与 OD 场景适配

表 1 显示，模型选择并不存在单一最优解。GRU 在学生项目中很实用，因为训练成本低；Graph WaveNet 对网络结构更敏感，但需要稳定图定义；Transformer 能捕获长程依赖，却可能在中小规模数据上出现“看似复杂、实则泛化不足”的问题。此处的反直觉结论是：越先进的模型并不必然越适合课程项目，过程可复现性、调参成本和解释成本必须被纳入技术选择。

技术比较采用“适用性”而非“流行度”作为判断标准。对学生团队而言，训练成本超过 12 小时、参数解释困难、调试依赖昂贵显卡的模型，即便论文指标更高，也可能降低交付稳定性。报告由此采用分层选型：历史均值保底，GRU 提供时间基线，图模型承担主力预测，生成式 AI 只在过程辅助中受控使用。

5. 场景矩阵与需求映射

表 1 典型交通场景与 AI 技术适配矩阵

维度	数据敏感性	模型重点	过程风险	应用价值
早高峰潮汐	高	短时突增捕获	漂移	调度优先
极端天气	高	外生变量融合	样本稀缺	预警
大型活动	中高	异常检测	标签滞后	应急
低频边缘区域	中	稀疏补偿	过拟合	覆盖
跨城区通勤	高	长程依赖	时延	规划

表 2 典型交通场景与 AI 技术适配矩阵

场景矩阵把业务需求翻译为技术选择。早高峰场景对短时突增敏感，模型需要关注最近 3-6 个时间片；极端天气对外生变量依赖更强，天气编码缺失会直接拉高误差；大型活动更像异常检测任务，平均 MAE 无法独立说明成败。

因此，报告不建议使用单一指标评价全部场景。高频主干区域可采用 MAE/RMSE，边缘区域应增加非零 OD 召回率，大型活动场景则需要事件窗口内的高流量命中率。

场景矩阵还能帮助团队防止需求膨胀。每增加一个场景，就应同步增加验收指标、数据来源和失败边界；否则场景描述越丰富，项目风险越不可控。本文将五类场景纳入分析，但真正建议作为第一阶段交付门禁的只有早晚高峰、雨天扰动和非零 OD 召回三项，因为它们既有数据支撑，也能被可视化验证。

6. 数据工程与特征构造

OD 预测项目的技术成败，超过 50% 取决于数据工程，而不是模型结构。原始订单记录包含上车点、下车点、时间戳、订单状态与异常取消标识；清洗阶段删除坐标漂移、时间倒置和无效订单，最终保留 86.8 万条有效样本。经网格映射后，单日形成 24 个 OD 矩阵，每个矩阵包含 65,536 个可能单元。

特征构造采用三类变量：历史窗口特征、空间邻接特征和外生上下文特征。历史窗口覆盖最近 6 小时与前一日同小时；空间邻接通过网格距离、道路连通性和历史共现构建；外生变量引入降雨等级、工作日标识和大型活动标签。为什么不只喂给模型原始订单？因为模型无法自动弥补数据采样偏差，特征工程仍然是软件过程中的质量控制点。

特征组	字段示例	处理方式	预期作用
时间特征	小时/星期/节假日	周期编码	捕获通勤节律
空间特征	网格邻接/距离	图矩阵	表达区域扩散
天气特征	降雨/温度	归一化	识别外部扰动
历史特征	t-1 到 t-6	滑动窗口	增强短期记忆

表 3 特征工程设计

数据工程阶段的一个关键判断是：不要把所有缺失都简单填零。对于无订单网格，零代表真实无需求；对于天气字段缺失，零可能代表未知；对于跨天订单，时间差异常可能来自系统记录错误。三类“空值”含义不同，处理方式也必须不同。若数据清洗把语义差异抹平，模型会在训练时吸收错误信号。

7. 模型比较与技术选择

图 2 代表模型在 OD 预测任务中的综合得分




图 2 代表模型在 OD 预测任务中的综合得分

综合评分由常规 MAE、高峰 MAE、非零 OD 召回率和训练成本四项归一化后加权得到。OD-Predictor 得分最高，并不意味着它在全部细分场景中压倒其他模型；它的优势来自更均衡的误差分布，尤其是在高流量 OD 与边缘区域之间取得折中。

在课程项目交付条件下，技术路线选择 OD-Predictor 作为主模型，同时保留 Historical Average 作为锚点基线。锚点基线很朴素，却能防止复杂模型在异常切分中“退化而不自知”。一个没有强基线的 AI 项目，往往会把偶然提升误判为方法创新。

综合得分的存在并不否认细分指标的价值。它更像项目管理中的汇总视图，用于快速比较候选方案；真正决定能否发布的仍是场景门禁。OD-Predictor 在综合分上领先，但报告仍保留 Graph WaveNet 作为备用方案，因为后者结构成熟、训练稳定，当主模型在新数据上漂移时可承担回退角色。

8. AI 辅助软件过程场景

生成式 AI 并不直接替代开发者，它更适合作为过程放大器嵌入需求、测试和复盘环节。需求阶段，AI 可将调度员口头描述转换为用户故事；测试阶段，AI 根据接口字段生成边界用例；文档阶段，AI 对实验日志开展结构化摘要。

但过程使用必须加上审查闸门。项目中的订单样本、城市区域标签和接口地址均属于敏感信息，不能直接输入外部模型。采用本地脱敏模板后，AI 只接收字段结构和伪造样例，而不接触真实轨迹。这样做看似降低了便利性，却换来可控的合规边界。

- 需求拆解：将“晚高峰提前预警”拆为时间窗口、区域范围、指标阈值。
- 测试生成：根据 OD 查询接口自动补齐空矩阵、异常网格、跨天窗口等用例。
- 实验复盘：从训练日志中提取误差峰值、失败批次和参数变化。
- 文档同步：把模型版本、数据版本和指标表合并为交付说明。

AI 辅助软件过程尤其适合处理“重复但不能随意”的任务。需求表、测试用例和实验摘要都具有模板性，人工长期维护容易疲劳；但这些内容又涉及质量判断，不能完全交给模型。较合理的做法是让 AI 生成候选草稿，由责任人审查并留下修订记录。这样既利用效率，又避免自动化幻觉进入正式交付。

9. 场景一：早晚高峰预测

早晚高峰是智能交通 OD 预测最具业务价值的场景。以工作日 7:00-9:00 和 17:00-19:00 为窗口，主城区到商务区的 OD 需求比普通时段高出 2.4 倍，且方向性显著。模型若只预测总量，会把“从住宅区到商务区”和“从商务区到住宅区”混为一谈，调度建议随之失真。

在示意实验中，OD-Predictor 将高峰窗口 MAE 从 Graph WaveNet 的 5.84 降至 5.41，非零 OD 召回率提升至 71.3%。该提升看似只有 7.4%，但对应到实际调度端，相当于在 20 个高需求网格中多识别 1-2 个候选区域。软件过程因此需要把高峰指标设为发布门禁，而不是附属观察项。

指标	Graph WaveNet	OD-Predictor	变化
高峰 MAE	5.84	5.41	-7.4%
非零 OD 召回	67.8%	71.3%	+3.5pp
高流量命中	69.1%	73.6%	+4.5pp

表 4 高峰场景对比

高峰预测的难点在于方向性和提前量。若系统只在需求已经爆发后给出热区，调度价值会明显下降；若提前量太长，预测又会被不确定性削弱。报告建议采用 1 小时作为课程项目的主要提前窗口，同时记录 2 小时预测作为观察指标，以便展示模型在短期与中期之间的性能折中。

10. 场景二：极端天气与异常事件

暴雨、台风预警和大型活动会打破历史模式。常规模型在这些窗口中往往出现系统性低估，因为训练集中的异常样本占比不足 6%。这不是简单增加 epoch 能解决的问题，而是数据分布与业务事件之间的结构性错配。

针对异常事件，技术方案引入事件标签和天气强度编码，并在评估阶段单独抽取事件窗口。实验显示，加入天气变量后，暴雨时段 MAE 从 7.02 降至 6.31；但大型活动散场场景仍存在 10 分钟以上的响应滞后。AI 技术能够提前暴露风险，却不能替代现场调度规则。

反直觉的是，异常场景下过度追求平均精度可能误导管理者。某些区域即便预测误差较大，只要能提前识别方向和等级，仍具有调度价值；相反，平均误差很低但漏掉两个核心枢纽，系统价值会被迅速削弱。

异常事件场景提醒团队，AI 不是经验规则的替代物。暴雨日样本不足时，模型可识别需求偏移，却难以准确估计极端峰值；大型活动样本缺少官方事件表时，订单数据只能事后反映变化。系统应把异常预测输出为“风险等级”和“候选区域”，而非绝对精确的订单数，避免给用户造成过度确定感。

11. 场景三：区域供需失衡识别

供需失衡并不等同于订单量高。某个区域订单需求稳定增长，但车辆供给同步增加，调度压力可能并不突出；另一个低频区域即便订单绝对值不高，只要供给长期不足，也会产生用户等待时间升高。OD 预测需要与车辆供给、等待时长和取消率联动。

在验证样例中，系统将 OD 预测结果转化为“缺口指数”：预测需求减去可用运力，再按等待时长加权。排名前 10 的网格中，7 个与历史高取消率区域重合，说明 OD 预测对供需识别具有辅助意义。不过，模型不能直接决定调度策略，因为司机行为、平台补贴和道路管制都会改变实际响应。

区域类型	预测需求	可用运力	缺口指数	建议
商务核心区	高	中	0.78	提前补车
交通枢纽	中高	低	0.82	重点预警
高校周边	中	中	0.41	观察
远郊居住区	低中	低	0.55	低频补偿

表 5 供需失衡场景示例

供需失衡分析把 OD 预测从“看图”推进到“辅助决策”。模型输出若只停留在矩阵热力图，使用者仍需自行判断哪些区域需要调度；加入可用运力、等待时长和取消率后，预测结果才转化为缺口指数。该指数并非最终命令，而是帮助调度员缩小搜索范围，把注意力集中到最可能失衡的区域。

12. 技术应用边界与伦理风险

AI 交通预测容易被包装为“更智能的调度”，但其边界必须被写入过程文件。数据层面，轨迹记录具有强隐私属性，即使去除姓名和电话，连续时间-空间轨迹仍可能被重新识别；模型层面，高需求区域被反复强化后，低频区域可能长期被忽略；管理层面，预测结果若被过度依赖，现场经验会被压缩。

报告建议建立三条边界：敏感字段脱敏率达到 100%，真实坐标只保留网格级编号；模型输出必须附带置信度和适用场景，不允许以单一分数替代调度判断；异常事件必须保留人工确认通道。技术不是中立的，尤其当它进入城市运行系统时，更需要被过程约束。

- 隐私边界：禁止在文档和提示词中暴露原始坐标与订单编号。
- 公平边界：低频区域需设置最低召回监控，避免模型只服务高频区域。
- 解释边界：每次发布必须包含典型成功案例与失败案例。
- 责任边界：AI 结果用于辅助，不作为唯一调度依据。

伦理边界不应只写在结尾，而应嵌入数据、模型和发布过程。数据层的网格化能降低隐私风险，模型层的置信区间能限制误用，应用层的人工确认能保留责任归属。若这些约束缺失，技术越有效，越可能放大偏差。智能交通系统连接真实城市空间，不能只以模型分数评判价值。

13. 调研结论与选型建议

本报告认为，智能交通 OD 预测项目的 AI 技术选型应采取“稳健基线 + 图结构模型 + 过程型 AI 辅助”的组合路线。稳健基线保证可解释与可回退，图结构模型处理空间关联，生成式 AI 则嵌入需求、测试和文档流程，减少重复劳动。

技术调研的关键结论并非“选择最复杂模型”，而是建立可持续的软件过程：数据能追踪，实验能复现，指标能分层，异常能解释。若把 AI 视为一次性算法展示，项目很快会停留在论文式结果；若把 AI 纳入过程资产，它才可能转化为长期可维护的交通预测能力。

下一阶段建议围绕三项任务展开：补充异常事件样本，构建高峰场景专用验证集；把数据版本、模型版本和评估报告绑定为发布包；引入 AI 辅助测试，但保留人工审核和隐私脱敏。

最终选型建议强调可落地性：课程项目可优先完成单城市、离线验证和可视化演示，再逐步扩展到在线推理、跨城泛化和持续监控。这样的路线看似保守，却能在有限时间内保住核心证据链。AI 技术调研的终点不是“列出先进模型”，而是为后续过程定义、改进方案和应用验证提供一致依据。