

AI 技术应用验证报告

1. 验证目标与实验对象

智能交通 OD 预测项目以“区域之间的出行需求”为建模对象，将城市划分为 16×16 网格，以 60 分钟为时间粒度，预测未来 12 个时间步的 OD 矩阵。项目并非单纯追求一个漂亮的模型分数，而是把数据治理、模型训练、过程评估和调度应用连接为一条可审计的软件过程链。

本报告验证 AI 技术在智能交通 OD 预测项目中的应用效果。验证对象不是一个孤立模型，而是一套从数据抽取、特征构造、模型训练、对比评估到误差诊断的技术链。报告采用 Markdown 式结构，重点回答三个问题：模型是否优于基线？提升来自哪里？在什么场景下仍然不可靠？

验证结论将服务于软件过程改进：若实验无法复现，模型不进入候选版本；若平均指标提升但高峰场景失败，模型不得作为发布模型；若应用收益不能被案例解释，结果只作为研究观察。

验证目标被设定为“证明可用并说明边界”，而不是单纯追求最高分。AI 应用验证若只输出一张结果表，很容易掩盖样本切分、异常场景和复现稳定性问题。报告将平均指标、分场景指标、消融实验与案例归因放在同一框架下，目的是让结论既有数值支撑，也能承受追问。

2. 数据集与实验设定

实验构造某城市 90 天网约车订单样本，共 92.4 万条原始记录，清洗后保留 86.8 万条有效订单。空间层面采用 16×16 网格，时间层面采用 60 分钟粒度；输入窗口为过去 24 小时，预测窗口为未来 12 小时。数据按时间顺序划分，前 70% 用于训练，中间 15% 用于验证，最后 15% 用于测试，避免随机切分造成信息泄漏。

数据项	数值	说明
原始订单	924,000	含取消与异常记录
有效订单	868,000	清洗后样本
时间跨度	90 天	连续自然日
空间网格	16×16	256 个区域
预测步长	12	未来 12 小时


表 1 数据集设定

该数据规模足以支撑课程级验证，但不足以证明跨城市泛化。报告中的结论应理解为项目内部验证，而非通用交通预测定律。

数据设定采用时间顺序切分，这一点对交通预测尤其重要。随机切分会让未来模式泄露到训练集中，模型看似准确，实际部署时却失去优势。90 天样本虽然不算庞大，但足以覆盖多个工作周和周末节律；不足之处在于极端天气和大型活动样本较少，报告会在后续局限性中单独说明。

3. 验证流水线

图 5 AI 技术应用验证流水线



验证报告采用“指标-案例-边界”三层证据，避免只凭单一平均误差做判断。

图 1 AI 技术应用验证流水线

验证流水线由数据抽取、训练验证、对比实验、消融实验、误差诊断和结论输出组成。每个环节均生成可审计产物：数据卡片、配置文件、训练日志、指标表、误差案例和结论说明。

这种设计避免了“只展示最好结果”的倾向。模型表现被放在多个证据层中检查：平均指标说明整体趋势，分场景指标揭示业务价值，误差案例暴露失败边界。

流水线设计还服务于复现。数据抽取脚本输出样本规模，训练脚本记录随机种子，对比实验统一配置，误差诊断保存高误差样本编号。任何读者若需要复查结论，都能沿着流水线找到证据。验证报告由此不只是结果汇报，更是软件过程中的质量证明材料。

4. 模型与参数配置

模型	核心结构	输入窗口	主要参数	用途
Historical Avg	历史均值	同小时/同星期	无训练参数	基线
GRU	循环网络	24 小时	hidden=64	时间基线
STGCN	时空卷积	24 小时	channels=64	空间基线
Graph WaveNet	自适应图卷积	24 小时	layers=4	强基线
OD-Predictor	图注意力+残差校正	24 小时	heads=4	候选模型

表 2 模型配置

参数配置遵循“可复现优先”原则。所有模型采用相同数据切分、相同输入窗口和相同评价指标；随机种子固定为 2026、2027、2028 三组，最终结果取平均。这样做会增加实验成本，却能降低偶然波动对结论的影响。

OD-Predictor 采用图注意力捕捉区域依赖，并加入残差校正模块处理高流量 OD。该结构并不追求过度复杂，而是针对 OD 矩阵的稀疏性和高峰集中性做定向补偿。

模型配置刻意保留简单基线。Historical Average 看起来朴素，却能揭示任务下限；GRU 代表纯时间建模，STGCN 和 Graph WaveNet 代表空间结构建模，OD-Predictor 作为候选模型接受比较。没有这些基线，主模型的提升幅度就缺乏参照，答辩时也难以说明“好在哪里”。

5. 评价指标体系

评价指标包含整体误差、非零 OD 误差、高流量命中率、峰值时段误差和推理延迟。仅使用 MAE 会掩盖大量零单元带来的虚假稳定，因此报告把非零 OD 和高流量 OD 单独列出。

指标	含义	业务解释	阈值
MAE	平均绝对误差	整体预测稳定性	≤ 5.20
RMSE	平方误差敏感	大误差惩罚	≤ 9.20
MAPE	相对误差	跨区域比较	$\leq 18\%$
非零召回	非零 OD 命中	是否漏掉真实需求	$\geq 68\%$
推理延迟	接口响应时间	能否在线使用	≤ 2 秒

表 3 指标体系

指标体系强调分层。平均误差是必要证据，却不是充分证据；交通调度场景更关心错误发生在哪里、发生在什么时候、是否影响决策。

指标体系的设计避免单一数字支配结论。OD 矩阵高度稀疏，模型只要预测大量零值就能获得不错的平均误差；但业务真正关心的是非零需求和高流量区域。报告把非零召回、高峰 MAE 和推理延迟并列为核心指标，防止模型在统计上成功、在业务上失败。

6. 对比实验结果

图 6 不同模型 MAE 对比（越低越好）




图 2 不同模型 MAE 对比（越低越好）

模型	MAE	RMSE	MAPE	非零召回
Historical Avg	8.42	15.73	31.5%	42.6%
GRU	6.91	12.84	25.7%	55.2%
STGCN	5.87	10.42	21.3%	63.9%
Graph WaveNet	5.41	9.76	19.8%	67.8%
OD-Predictor	4.96	8.93	17.6%	71.3%

表 4 对比实验结果

OD-Predictor 在四项指标上取得最佳结果，MAE 相比 Graph WaveNet 下降 8.3%，相比 Historical Average 下降 41.1%。提升并非来自单一模块，而是图结构、外生变量和残差校正共同作用。

对比实验显示主模型领先，但结果仍需谨慎解释。MAE 下降 41.1% 相对历史均值非常明显，不过这部分提升包含了深度模型对时间节律的基本学习；相对 Graph WaveNet 的 8.3% 更能体现结构改进价值。报告因此同时呈现绝对提升和相对强基线提升，避免夸大结论。

7. 训练收敛与稳定性

图 7 验证集 MAE 收敛趋势




图 3 验证集 MAE 收敛趋势

图 3 显示，OD-Predictor 在第 7 轮后逐步收敛，验证集 MAE 稳定在 4.95 左右。Graph WaveNet 收敛速度略慢，GRU 在第 6 轮后几乎不再改善，说明单纯时间模型难以继续吸收空间结构信息。

稳定性验证采用三组随机种子。OD-Predictor 的 MAE 标准差为 0.06，低于 STGCN 的 0.11，说明候选模型对初始化相对不敏感。对课程项目而言，稳定性比一次性最优值更重要，因为它决定结果能否被他人复跑。

收敛曲线还能暴露训练策略是否合理。若验证误差前期快速下降、后期稳定，说明学习率和模型容量基本匹配；若训练误差持续下降而验证误差反弹，则可能过拟合。当前曲线没有显著反弹，但第 8 轮后收益变小，后续训练可采用早停策略节省算力。

8. 消融实验

实验设置	MAE	高峰 MAE	非零召回	变化说明
完整模型	4.96	5.41	71.3%	基准
去除天气特征	5.18	5.73	69.4%	异常场景退化
去除图结构	5.36	5.92	65.8%	空间依赖下降
去除残差校正	5.21	5.88	68.2%	高流量低估
仅时间特征	6.74	7.31	54.9%	退化明显

表 5 消融实验结果

消融结果表明，图结构对空间关联贡献最大，残差校正主要改善高峰和高流量 OD，天气特征在异常天气窗口作用明显。若只看整体 MAE，天气特征贡献似乎有限；但在暴雨窗口，其误差下降达到 10.1%。这说明分场景评估不可省略。

一个值得警惕的现象是：加入更多特征并不总是提升结果。部分 POI 特征在低频区域引入噪声，导致边缘 OD 召回下降 1.2 个百分点。特征工程需要被验证，而不是被默认为“越多越好”。

消融实验提供因果线索。完整模型优于删减版本，说明图结构、天气特征和残差校正并非装饰模块。尤其是去除图结构后非零召回明显下降，表明区域关系对 OD 预测确有贡献。与此同时，POI 特征引入噪声的现象提醒团队，特征不是越多越好，未经验证的变量可能伤害泛化。

9. 高峰场景验证

高峰场景单独抽取工作日 7:00-9:00 和 17:00-19:00 样本。OD-Predictor 在该窗口内高流量命中率达到 73.6%，比 Graph WaveNet 高 4.5 个百分点。更重要的是，模型能提前识别商务区入口和交通枢纽周边的需求上升。

场景	样本占比	OD-Predictor MAE	Graph WaveNet MAE	改进
早高峰	8.3%	5.38	5.81	7.4%
晚高峰	9.1%	5.44	5.87	7.3%
普通时段	82.6%	4.88	5.30	7.9%

表 6 高峰与普通时段对比

高峰结果验证了模型的业务价值，却没有解决全部问题。个别交通枢纽在突发拥堵后仍出现低估，说明模型对道路事件的即时感知不足。后续若接入实时路况或拥堵指数，可能进一步降低响应滞后。

高峰验证强调应用价值。普通时段误差下降固然重要，但调度系统真正紧张的时段集中在早晚高峰。模型在高峰窗口保持改善，说明其结果可能转化为提前补车、热区预警和候选线路调整。若高峰失败，即便全天平均结果好看，也不宜作为发布候选。

10. 异常天气场景验证

异常天气验证选取 9 个降雨日，其中小雨 5 天、中雨 3 天、暴雨 1 天。加入天气变量后，雨天 MAE 从 6.97 降至 6.31，改善幅度为 9.5%；暴雨日改善更明显，但仍高于普通工作日。

这个结果揭示了 AI 模型的边界：外生变量能帮助模型识别分布变化，却无法凭空学习训练集中几乎不存在的极端事件。若暴雨样本只有 1 天，模型对暴雨交通规律的理解仍然脆弱。

天气类型	天数	无天气特征 MAE	加入天气特征 MAE	改善
小雨	5	6.42	6.05	5.8%
中雨	3	7.08	6.39	9.7%
暴雨	1	8.13	7.18	11.7%

表 7 天气特征验证

天气验证揭示样本稀缺问题。加入天气变量后雨天误差下降，说明外生信息有效；但暴雨样本只有一天，统计稳定性不足。报告没有把暴雨结果写成强结论，而把它定义为观察性证据。这样的克制比单纯宣称“模型适应极端天气”更符合工程报告的可信表达。

11. 误差案例分析

误差案例比平均指标更接近真实问题。测试集中抽取 50 个高误差样本后发现，36% 与突发天气有关，28% 与大型活动或枢纽散场有关，22% 来自低频边缘 OD，剩余 14% 与数据噪声或网格边界有关。

案例类型	占比	典型表现	改进建议
天气扰动	36%	需求突然转向地铁站/商圈	强化天气与路况特征
大型活动	28%	散场后短时峰值	引入事件日历
低频 OD	22%	预测为零但实际有需求	稀疏补偿
网格边界	14%	相邻格误差交换	优化网格划分

表 8 高误差案例归因

案例分析说明，模型失败并不总是算法失败，有时是场景信息缺失，有时是空间划分粗糙。若没有误差归因，团队很容易把所有问题推给模型结构，继而陷入无效调参。

误差归因让改进方向更具体。若 36% 高误差来自天气扰动，团队应补充天气与路况特征；若 28% 来自大型活动，事件日历比增加网络层数更有价值；若低频 OD 占 22%，则需要稀疏补偿或重采样。案例分析把“模型不准”拆成可处理的问题。

12. 应用价值与局限性

在模拟调度场景中，系统提前 1 小时输出高需求 OD 排名。与历史均值相比，OD-Predictor 使前 20 个高需求区域命中数量从 12 个提升至 15 个，候选调度区域覆盖率提高 15 个百分点。该结果具有明确应用价值。

然而，预测精度提升是否必然意味着系统价值提升？答案并不绝对。若调度系统无法及时响应，或司机接单行为受补贴、道路管制影响，模型预测再准确也可能转化失败。AI 技术提供的是决策信号，不是自动完成交通治理。

- 局限一：样本来自单城市，跨城市泛化未经验证。
- 局限二：异常事件样本不足，极端场景结论需谨慎。
- 局限三：指标侧重预测误差，尚未完整评估调度收益。
- 局限四：隐私脱敏与模型解释仍需制度化流程支持。

应用价值评估必须连接真实决策。前 20 个高需求区域命中数量从 12 提升到 15，意味着调度员可以更早关注关键区域；但如果可用车辆不足，预测仍无法直接降低等待时间。因此，验证报告把模型价值表述为“辅助决策信号增强”，而不是直接承诺运营收益。

13. 验证结论与后续工作

验证结果表明，OD-Predictor 在整体误差、高峰场景、非零 OD 召回和异常天气窗口中均优于对比模型，具备作为课程项目候选模型的条件。其优势主要来自图结构建模、外生变量融合和残差校正，而非单纯增加网络深度。

报告也保留必要克制：当前验证不能证明模型适用于所有城市、所有天气和所有运行周期。后续工作应补充跨月测试、异常事件样本和在线延迟评估，并把验证流水线纳入软件过程门禁。

后续任务	目标	时间	验收物
跨月验证	检查时间泛化	1 周	cross_month_report
事件样本补充	增强异常鲁棒性	2 周	event_data_card
在线压测	验证接口延迟	3 天	latency_report
过程门禁	绑定发布流程	1 周	gate_checklist

表 9 后续验证计划

后续工作聚焦证据链延伸。跨月验证用于确认时间泛化，事件样本补充用于提高异常鲁棒性，在线压测用于验证部署可行性，过程门禁用于把实验结论转入软件过程。只有这些任务完成后，模型才能从课程演示进一步接近真实应用。