

AI 技术应用验证报告

本报告围绕智能交通 OD 预测项目构造 AI 技术应用验证方案，验证对象为“OD-Predictor”示意模型。报告采用课程项目可接受的实验化写法：数据与指标具有工程合理性，数值用于说明方法差异与过程验证逻辑，不宣称来自真实生产系统。

1 验证目标与实验问题

验证目标不是单纯证明某个模型“更强”，而是检验 AI 技术能否在智能交通场景中产生稳定、可解释、可复现的改进。报告设置三个问题：模型是否降低总体预测误差？模型是否改善高流量 OD 的识别能力？当天气、节假日和活动扰动出现时，模型是否仍保持可接受的鲁棒性？

这些问题之所以并列，是因为交通预测存在明显的指标错位。总体误差低，可能只是因为零值 OD 占比过高；高流量 OD 召回率高，才更接近调度价值。课程验证若只展示一个 MAE 数字，难以说明 AI 技术是否真正适合该场景。

2 数据集与实验环境

实验数据被设定为某城市 90 天出租车订单与外部环境数据。空间上采用 16×16 网格，时间粒度为 60 分钟，预测窗口为未来 12 个时间步。数据集包含约 86 万条订单记录，转换为 2160 个时间片和 141.6 百万个 OD 单元，其中非零 OD 占比约 1.9%。天气字段包含降雨、温度、风力和能见度；POI 字段覆盖交通枢纽、商业中心、学校、医院和大型场馆。

项目	配置
空间划分	16×16 城市网格
时间粒度	60 分钟
历史窗口	过去 24 小时 + 同星期历史片段
预测窗口	未来 12 个时间步
训练/验证/测试	70% / 15% / 15% 按时间顺序切分
评价指标	MAE、RMSE、MAPE、高流量 MAE、非零 OD MAE
硬件环境	8 核 CPU、16GB 存、中端 GPU（课程实验假设）

表 1 实验数据与环境配置

3 模型与基线设置


验证选择五类模型。Historical Average 作为朴素基线，用同星期同时间片平均值预测未来需求；GRU 捕捉时间序列变化，但缺少显式空间结构；STGCN 引入图卷积和时间卷积；Graph WaveNet 通过自适应图结构学习潜在空间依赖；OD-Predictor 在 Graph WaveNet 思路上加入轻量时间注意力、天气特征和零膨胀校准，用于处理 OD 稀疏性。

4 对比实验结果

模型	MAE	RMSE	MAPE	高流量 MAE	非零 OD MAE
Historical Average	8.42	15.73	31.5%	21.84	18.26
GRU	6.91	12.84	25.7%	18.33	15.74
STGCN	5.87	10.42	21.3%	15.42	13.15
Graph WaveNet	5.41	9.76	19.8%	14.18	12.62
OD-Predictor	4.96	8.93	17.6%	12.74	11.38

表 2 OD 预测模型对比实验结果

不同模型在 OD 预测任务上的 MAE 对比



注：数据为课程项目验证中的示意性结果。

图 1 不同模型在 OD 预测任务上的 MAE 对比

实验结果显示，OD-Predictor 的 MAE 较 Historical Average 降低 41.1%，较 GRU 降低 28.2%，较 Graph WaveNet 降低 8.3%。更关键的是，高流量 MAE 从 Graph WaveNet 的 14.18 降至 12.74，说明改进并非只来自大量零值单元，而是对业务关键 OD 也产生了收益。

5 消融实验与模块贡献

模型变体	MAE	变化幅度	解释
完整模型	4.96	-	基准结果
去掉天气特征	5.28	+6.5%	端天本差上升
去掉图结构	5.53	+11.5%	跨区域空间依赖受损
去掉时间注意力	5.38	+8.5%	历史高峰模式捕捉能力下降
去掉零膨胀校准	5.71	+15.1%	稀疏 OD 被过度平滑

表 3 模型消融实验结果

关键模块消融实验结果




图 2 关键模块消融实验结果

消融果明，零膨校准稀疏 OD 最敏感，去除后 MAE 上升 15.1%；图结构和时间注意力分别影响空间依赖与周期规律。天气特征的整体贡献看似较小，但在暴雨日样本中贡献明显。换句话说，模块价值不能只看全局平均值，必须进入具体交通场景。

6 场景化验证

场景	样本占比	关键指标	验证结果
工作日早高峰	18.4%	高流量 OD 召回率	OD-Predictor 达到 78.6%，较 Graph WaveNet 提升 6.9 个百分点
暴雨天	7.2%	常日 MAE	由 6.34 降至 5.71，下降 9.9%
大型活散	3.5%	Top-20 点 OD 命中率	达到 75.0%，但仍存在低

			尖峰
低需求夜间	24.1%	误报率	保持在 4.8%，未明显增加无效调度风险

表 4 场景化验证结果

场景化结果揭示了一个更接近工程实际的事实：模型在常规工作日表现稳定，在极端天气中仍有收益，但大型活动散场仍是薄弱环节。活动流量具有短时爆发、方向集中和历史样本稀缺三个特征，单靠历史订单很难充分学习。若后续接入活动日历、地铁末班车时间和场馆容量数据，模型对尖峰 OD 的低估可能进一步缓解。

7 过程验证与复现性

本次验证同时检查软件过程质量。每轮实验绑定数据版本、代码提交编号、参数配置和结果文件；评估脚本自动生成 MAE、RMSE、MAPE 与高流量 OD 指标；图表由统一脚本输出，避免人工复制错误。经过三次重复运行，OD-Predictor 的 MAE 波动范围为 4.91-5.03，标准差约 0.05，说明实验结果具备基本稳定性。

过程指标	目标值	验证值	评价
实验记录完整率	≥95%	97.3%	达标
单次复现实验耗时	≤20 分钟	16 分钟	达标
表自动生成比例	≥80%	86.7%	达标
人工核覆盖率	100%	100%	达标
异常样本解释准确率	≥70%	68.5%	未完全达标

表 5 AI 应用验证中的过程质量指标

8 局限性与批判性分析

实验仍有局限。数据规模虽然足以支撑课程验证，却不足以代表真实城市全年复杂交通；模拟数据中的活动、天气和 POI 标注也可能比现实更整齐。模型在高流量 OD 上取得改善，并不意味着它可以直接替代人工调度。交通系统受到政策、突发事件、道路施工和公众行为变化影响，很多因素无法由订单历史完全解释。

更值得警惕的是指标崇拜。一个 MAE 更低的模型，如果推理速度慢、解释困难、维护成本高，未必适合落地。反过来，一个略微牺牲总体误差但能够稳定输出热点排序和置

信度区间的模型，可能更受调度人员欢迎。AI 技术验证不应只证明“模型能算”，还要证明“结果能被使用、风险能被发现、过程能被复现”。

9 结论

验证结果表明，OD-Predictor 在总体误差、高流量 OD 和异常天气场景中均优于基线模型，说明时空图学习、时间注意力和零膨胀校准具有应用价值。与此同时，实验也表明 AI 技术必须嵌入软件过程：没有数据版本、实验追踪、自动化评估和人工复核，模型精度很难转化为可信成果。对本课程项目而言，最重要的结论并非某个模型取得了最低误差，而是 AI 应用验证需要同时回答技术有效性、场景适配性和过程可控性三个问题。

参考资料

- [1] Wu Z., Pan S., Long G., Jiang J., Zhang C. Graph WaveNet for Deep Spatial-Temporal Graph Modeling. arXiv:1906.00121.
- [2] Yu B., Yin H., Zhu Z. Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting. IJCAI 2018.
- [3] Li Y., Yu R., Shahabi C., Liu Y. Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting. arXiv:1707.01926.
- [4] NIST, Artificial Intelligence Risk Management Framework (AI RMF 1.0), 2023.